



Universidade Estadual de Campinas
ME613 - Análise de Regressão

**Análise Preditiva do Mercado Imobiliário de Seattle por Meio de
Modelos de Regressão**

Autores:

Amanda Nogueira Pereira	257134
Arthur Lourenço Narcizo da Silva	236043
Gabriel Campovilla da Silva	193625

Docente:

Prof.^a Tatiana Benaglia

Campinas - SP
Novembro de 2025

1 Introdução e Motivação

Este trabalho aplica as ferramentas e metodologias de análise de regressão para investigar os principais fatores determinantes dos preços de imóveis na cidade de Seattle. Para isso, utilizaremos um conjunto de dados abrangente que contém informações detalhadas sobre 21.613 propriedades listadas nesta região. O objetivo central é desenvolver e validar um modelo de regressão que seja capaz de prever, com base em variáveis explicativas como metragem quadrada, número de quartos, localização e condição do imóvel, o seu valor de mercado. A análise exploratória inicial servirá para fundamentar a seleção das variáveis e verificar pressupostos do modelo, garantindo a robustez das nossas inferências e previsões sobre a dinâmica imobiliária de Seattle.

2 Materiais e Métodos

A análise do conjunto de dados de preços de imóveis foi realizada integralmente na linguagem de programação R, utilizando um robusto conjunto de bibliotecas. O processo metodológico seguiu as etapas de preparação, exploração e modelagem dos dados.

Inicialmente, na Análise Exploratória de Dados, foram gerados histogramas para observar a distribuição das variáveis numéricas, com foco especial no preço ajustado. Boxplots foram empregados para identificar outliers. A relação bivariada entre o `price_ajustado` e os demais preditores numéricos foi avaliada por meio de gráficos de dispersão. Gráficos de dispersão geográficos, usando longitude e latitude, visualizaram a distribuição espacial dos preços na área de Seattle. Finalmente, uma matriz de correlação foi calculada e plotada com `corrplot` para analisar a multicolinearidade e a força das relações lineares entre os preditores.

Em sequência, a etapa de inspeção utilizou funções como `glimpse()`, `summary()`, e `skim()` para um entendimento estrutural. O tratamento das variáveis foi crucial, começando pela `date`, que foi desmembrada em ano, mês e dia utilizando o pacote `lubridate`. O ajuste financeiro foi aplicado através da criação da variável `price_ajustado`, que corrigiu os preços de 2014 e 2015 por fatores de inflação (1,3616 e 1,3591, respectivamente) para garantir a comparabilidade monetária. Em seguida, as variáveis. Por fim, retiramos algumas colunas para a etapa de modelagem.

A Modelagem de Regressão começou com a Regressão por Múltiplos Quadrados Mínimos. Três modelos foram ajustados: um completo, um sem variáveis fatoriais, e um modelo base selecionado. Em seguida, a Regularização LASSO foi aplicada para a seleção automática de variáveis e controle do overfitting. A técnica envolveu a criação de uma matriz de design e o uso da função `cv.glmnet` (com $\alpha = 1$ e validação cruzada) para determinar o parâmetro de penalidade ideal $\lambda_{\min}$,

que minimiza o erro de predição. O modelo LASSO final foi ajustado, e a inspeção dos coeficientes não nulos permitiu identificar as variáveis mais relevantes para a predição do preço.

Para refinar a performance preditiva. O Modelo Logarítmico aplicou a transformação log na variável de resposta e em preditores selecionados para mitigar a assimetria e a heterocedasticidade, com o R^2 calculado após a transformação das predições de volta à escala original. O Modelo de Mínimos Quadrados Ponderados (WLS) foi testado como uma alternativa direta para corrigir a heterocedasticidade, usando pesos inversamente proporcionais ao quadrado dos valores ajustados do modelo OLS. A performance dos modelos Original, Logarítmico e WLS foi comparada graficamente através dos seus valores de R^2 . O modelo com melhor desempenho foi submetido a um Diagnóstico de Resíduos, com gráficos de Resíduos vs. Valores Ajustados e QQ-Plots, para verificar o atendimento às pressuposições de variância constante e normalidade dos erros.

3 Aplicação e Resultados

3.1 Análise Exploratória dos Dados

A base analisada contém 21.613 observações e 22 variáveis, incluindo atributos estruturais, geográficos e qualitativos das propriedades do condado de King (Seattle, EUA). O objetivo desta EDA é caracterizar a variável resposta (*price*) e descrever o comportamento das variáveis preditoras, destacando padrões, assimetrias e possíveis implicações para a modelagem.

O sumário estatístico mostra que *price* (Preço) apresenta grande dispersão, variando de US\$ 75,000 a US\$ 7,7 milhões, refletindo ampla heterogeneidade nos valores de mercado. Variáveis como *bedrooms* e *bathrooms* exibem forte assimetria, com valores máximos muito superiores aos quartis, sugerindo a presença de imóveis de alto padrão.

As variáveis de metragem *sqft_living* (área útil interna), *sqft_lot* (área total do terreno), *sqft_above* (área acima do nível do solo), *sqft_basement* (área de porão), *sqft_living15* (área útil média das casas vizinhas) e *sqft_lot15* (área média do terreno das casas vizinhas) apresentam grandes diferenças entre valores mínimos, medianas e máximos, indicando diversidade estrutural significativa entre as residências.

Nas características físicas, observa-se predominância de condição intermediária (*condition* entre 3 e 4) e qualidade construtiva entre 7 e 8 (*grade*), indicando imóveis majoritariamente de padrão médio. As variáveis geográficas (*lat* e *long*) possuem baixa variabilidade, como esperado para uma única região. Por fim, *yr_built* (Ano de construção) se distribui ao longo do século XX, enquanto *yr_renovated* (Ano de reforma) apresenta mediana zero, indicando que a maior parte das propriedades

nunca passou por reformas substanciais.

3.1.1 Distribuição da Variável Resposta (*price*)

A Figura 1 mostra que a distribuição de *price* é fortemente assimétrica à direita, com maior concentração entre USD 100.000 e USD 600.000. A cauda longa indica a presença de imóveis de alto padrão, alcançando valores acima de USD 8 milhões.




Figura 1: Distribuição da variável *price* (Preço).

3.1.2 Distribuições Univariadas das Variáveis Preditoras

A Figura 2 apresenta os histogramas das variáveis explicativas numéricas.




Figura 2: Distribuição univariada das variáveis preditoras.

Variáveis de área (*sqft_living* (Área útil interna da casa), *sqft_above* (Área construída acima do nível do solo), *sqft_lot* (Área total do terreno), *sqft_lot15* (Área média do terreno das casas vizinhas)) exibem forte assimetria positiva, com muitas residências pequenas e poucas com metragens muito elevadas. Variáveis de contagem, como *bedrooms* (Nº de quartos), *bathrooms* (Nº de banheiros) e *floors* (Nº de andares), mostram concentrações em valores específicos (ex.: 2–4 quartos e 1–3 banheiros), refletindo padrões construtivos comuns. Variáveis ordinais (*condition*, *grade*, *view*) apresentam distribuições não uniformes, indicando predominância de casas em condição mediana e padrão construtivo intermediário.

3.1.3 Análise de Outliers

A análise de outliers através de boxplots (Figura 3) e da (Tabela 1) revela padrões distintos entre as variáveis analisadas:

Tabela 1: Estatísticas Descritivas das Variáveis do Dataset Imobiliário

Variável	Mínimo	1º Quartil	Mediana	Média	3º Quartil	Máximo
Quartos	0.0	3.0	3.0	3.4	4.0	33.0
Banheiros	0.0	1.8	2.3	2.1	2.5	8.0
Área construída	290.0	1427.0	1910.0	2080.0	2550.0	13540.0
Área terreno	520.0	5040.0	7618.0	15107.0	10688.0	1651359.0
Andares	1.0	1.0	1.5	1.5	2.0	3.5
Classificação	1.0	7.0	7.0	7.7	8.0	13.0
Área superior	290.0	1190.0	1560.0	1788.0	2210.0	9410.0
Área porão	0.0	0.0	0.0	291.5	560.0	4820.0
Ano construção	1900.0	1951.0	1975.0	1971.0	1997.0	2015.0
Ano renovação	0.0	0.0	0.0	84.4	0.0	2015.0
Latitude	47.2	47.5	47.6	47.6	47.7	47.8
Longitude	−122.5	−122.3	−122.2	−122.2	−122.1	−121.3
Área const. 2015	399.0	1490.0	1840.0	1987.0	2360.0	6210.0
Área terr. 2015	651.0	5100.0	7620.0	12768.0	10083.0	871200.0
Preço	75000	321950	450000	540088	645000	7700000




Figura 3: Boxplots das variáveis *price*, *sqft_lot* e *sqft_living*.

Preço (*price*): Apresenta outliers extremamente expressivos, com valores que atingem até US\$ 8 milhões, significativamente superiores à maioria das observações que se concentram abaixo de US\$ 2 milhões.

Área do lote (*sqft_lot*): Mostra a presença mais marcante de outliers, com valores que alcançam 1.500.000 sqft, indicando propriedades com lotes excepcionalmente amplos, possivelmente rurais ou não edificadas.

Área Construída (*sqft_living*): Embora também apresente outliers superiores (até 5.000 sqft), estes são menos extremos em comparação com as demais variáveis, sugerindo maior homogeneidade na área construída das residências.

A concentração de outliers em *price* (Preço) e *sqft_lot* (Área total do terreno) reflete a heterogeneidade típica do mercado imobiliário, onde uma pequena parcela de propriedades possui características excepcionais.

3.1.4 Matriz de Correlação

A Figura 4 apresenta a matriz de correlação das variáveis numéricas, incluindo a variável resposta *price*, permitindo identificar relações lineares relevantes e possíveis indícios de multicolinearidade.




Figura 4: Matriz de correlação das variáveis numéricas.

Observa-se que *price* possui maior correlação com *grade* (Nível de qualidade da construção)(0,8), seguida por *sqft_living* (Área útil interna da casa) e *sqft_above* (Área construída acima do nível do solo) (0,6), confirmando a relevância da qualidade construtiva e da metragem na determinação do valor dos imóveis. Há também correlações moderadas com *bathrooms* (Nº de banheiros)e *view* (Nível da qualidade da vista).

Entre os preditores, nota-se forte correlação entre variáveis estruturais como *sqft_living* (Área útil interna da casa), *sqft_above* (Área construída acima do nível do solo), *sqft_living15* (Área média das casa vizinhas) e *bathrooms* (Nº de banheiros), sugerindo possível multicolinearidade a ser avaliada via VIF. Variáveis espaciais (*lat* (Latitude), *long* (Longitude)) apresentam correlações moderadas com o preço, enquanto *floors* (Nº de andares) e *condition* (Conservação da casa) exibem correlações fracas.

3.1.5 Preparação dos Dados e Ajuste Inflacionário

A etapa inicial da análise envolveu o carregamento de 21.613 observações de dados imobiliários. Foi realizada a limpeza, removendo variáveis redundantes como `...1`, *id* e *zipcode*, e variáveis como *view*, *waterfront* e *condition* foram corretamente transformadas em fatores.

Um passo fundamental para garantir a validade temporal do modelo foi o ajuste da variável dependente, o preço (*price*), pela inflação. Para este propósito, o ano de venda (*ano*) foi extraído da variável *date*. Para transações ocorridas em 2014, os preços originais foram multiplicados por

um fator de 1.3616, e para transações em 2015, o fator aplicado foi de 1.3591. Após este ajuste, o preço dos imóveis (baseado no resumo dos dados) variou de um mínimo de \$101.932 a um máximo de \$10.484.320.

3.2 Modelos de Regressão Base (OLS e LASSO)

3.2.1 Modelo Original de Mínimos Quadrados Ordinários (OLS)

O Modelo Original de Mínimos Quadrados Ordinários (OLS) foi aplicado utilizando todas as variáveis preditoras disponíveis. Este modelo demonstrou uma capacidade explicativa robusta, resultando em um R^2 Múltiplo de 0.6985 e um R^2 Ajustado de 0.6982.

A análise dos coeficientes do OLS revelou que muitas variáveis eram altamente significativas ($p < 2e-16$), com destaque para a `grade` (grau de construção), que apresentou o maior impacto positivo em magnitude padronizada ($\approx 1.337e + 05$ por unidade). Outras variáveis cruciais incluíram `sqft_living` ($1.981e + 02$ por `sqft`), `waterfront1` (adicionando $\approx 6.922e + 05$ ao preço base), `lat` (latitude, com contribuição positiva de $\approx 7.652e + 05$) e `long` (longitude, com contribuição negativa de $\approx -1.554e + 05$). Em contraste, o ano de construção (`yr_built`) apresentou um coeficiente negativo ($\approx -3.314e + 03$ por ano). Foi observado que o coeficiente para `sqft_basement` não foi definido (NA) devido a singularidades. O Erro Quadrático Médio (RMSE) para este modelo foi de 274.294,1.

3.2.2 Modelo LASSO

O Modelo LASSO (Least Absolute Shrinkage and Selection Operator) foi empregado para regularização, utilizando o λ mínimo de 571.635069. O LASSO realizou a seleção de variáveis e penalizou, resultando na remoção das variáveis `condition4` e `sqft_basement` (cujos coeficientes foram definidos como zero ou '.'). As métricas de desempenho do LASSO foram muito próximas às do OLS, apresentando um R^2 de 0.6985125 e um RMSE de 274310.4224.

3.3 Modelos Avançados: Logarítmico e WLS

Para mitigar potenciais problemas nos pressupostos da regressão, como a heterocedasticidade, dois modelos avançados foram explorados.

3.3.1 Modelo Logarítmico

O Modelo Logarítmico utilizou a transformação do logaritmo natural na variável dependente, $\log(\text{price})$, e em variáveis contínuas de área como $\log(\text{sqft_living} + 1)$. As previsões foram retransfor-

madras para a escala original e corrigidas pelo viés de retransformação (Duan's smearing estimator). Este modelo demonstrou o melhor desempenho em termos de precisão preditiva, alcançando o menor RMSE de 249.745,2. O R^2 corrigido do modelo logarítmico foi de 0.7507989.

Apesar da melhoria nas métricas de erro, a análise de VIF (Variance Inflation Factor) indicou pequenos problemas de multicolinearidade, com $\log(\text{sqft_living} + 1)$ atingindo 7.724283 e $\log(\text{sqft_above} + 1)$ atingindo 6.812918. Contudo, a análise visual dos resíduos sugere que a distribuição se aproxima mais da normalidade quando comparada aos modelos OLS.

3.3.2 Modelo de Mínimos Quadrados Ponderados (WLS)

O Modelo de Mínimos Quadrados Ponderados (WLS) foi ajustado utilizando pesos calculados a partir dos resíduos do Modelo Original [OLS], com o objetivo de corrigir a heterocedasticidade ao dar menos peso a observações com resíduos grandes.

Entretanto, o modelo WLS não conseguiu se enquadrar adequadamente nos pressupostos de regressão, conforme evidenciado pela análise diagnóstica dos resíduos:

- O gráfico Resíduos vs Fitted apresentava um padrão claro e sistemático, indicando violação da suposição de homocedasticidade
- O gráfico Scale-Location não apresentou boa distribuição, confirmando problemas de variância não constante
- O gráfico Q-Q Residuals mostrou calda para baixo em valores baixos e calda para cima em valores altos, indicando desvios da normalidade
- O gráfico Residuals vs Leverage apresentava uma linha 100% horizontal, sugerindo falta de influência adequada dos pontos de alavancagem

Mesmo com a aplicação de validação cruzada, o modelo WLS não se adequou satisfatoriamente, mantendo os padrões problemáticos nos resíduos e demonstrando instabilidade na performance preditiva entre diferentes folds da validação. Porém este modelo alcançou a maior capacidade de explicação da variância, com um R^2 Múltiplo de 0.8867. Todos os coeficientes selecionados mostraram-se altamente significativos ($p < 2e-16$), com *grade* ($\approx 2.332e + 05$) e *bedrooms* ($\approx 5.868e + 04$) sendo os mais impactantes. A análise de VIF para o WLS confirmou a baixa multicolinearidade, com o VIF mais alto sendo 2.279578 para *grade*. Apesar do alto poder explicativo, o WLS apresentou o maior RMSE na comparação métrica final, atingindo 318.614,5.

3.3.3 Resultados dos Modelos

A Tabela 2 comparativa de desempenho resume as métricas dos quatro modelos analisados:

Tabela 2: Comparação de Métricas de Desempenho dos Modelos

Modelo	R^2	RMSE
Original (OLS)	0.6985419	274.294,1
LASSO	0.6985125	274.310,4
Logarítmico	0.7507989	249.745,2
WLS	0.8866601	318.614,5

Em síntese, o Modelo Logarítmico demonstrou ser o mais eficaz em minimizar o erro de previsão (RMSE), sendo o modelo preferencial quando o foco é a acurácia da estimativa de preço. Por outro lado, o Modelo WLS, apesar de sua excelente capacidade de explicação da variância presente nos dados ($R^2 = 0.8867$), apresentou problemas significativos de enquadramento nos pressupostos de regressão, limitando sua utilidade prática para inferência.




Figura 5: plot modelo logarítmico com os valores ajustados




Figura 6: plot modelo mínimo quadrado ajustado com os valores ajustados

4 Conclusão

Este trabalho realizou uma análise abrangente dos fatores determinantes dos preços de imóveis em Seattle utilizando diferentes abordagens de modelagem estatística. A análise exploratória inicial revelou características importantes do conjunto de dados, incluindo a forte assimetria na distribuição dos preços e a presença significativa de outliers, especialmente nas variáveis de preço e área do lote.

A aplicação de diferentes técnicas de regressão permitiu comparar o desempenho preditivo de múltiplas abordagens. O modelo OLS original demonstrou boa capacidade explicativa ($R^2 = 0,6985$), enquanto o modelo LASSO, através de regularização, simplificou o modelo sem perda significativa de desempenho. Contudo, os modelos mais sofisticados apresentaram vantagens distintas.

O Modelo Logarítmico emergiu como a melhor opção para previsão de preços, alcançando o menor RMSE (249.745,2) entre todos os modelos testados. A transformação logarítmica mostrou-se eficaz em lidar com a heterocedasticidade e a assimetria nos dados, melhorando significativamente a acurácia preditiva e apresentando melhor enquadramento nos pressupostos de regressão.

Por outro lado, o Modelo WLS, apesar de destacar-se na explicação da variância dos dados (obtendo o maior R^2 de 0,8867), apresentou problemas de enquadramento evidenciados pelos padrões sistemáticos nos gráficos de resíduos, o que limita sua confiabilidade para inferência estatística.

As análises confirmaram que variáveis como qualidade construtiva (grade), localização geográfica (latitude/longitude), área construída e vista para água são os fatores mais determinantes para os preços dos imóveis em Seattle, consistentemente significativos em todos os modelos.

Em termos práticos, a escolha entre os modelos deve considerar o objetivo específico da análise: para fins de valuation e previsão de preços, recomenda-se o Modelo Logarítmico pela sua superior acurácia e melhor aderência aos pressupostos; para compreensão das relações subjacentes, o Modelo WLS oferece insights valiosos, mas requer cautela devido aos problemas identificados na análise de resíduos. Esta abordagem comparativa demonstra a importância de selecionar a técnica de modelagem adequada aos objetivos analíticos específicos no mercado imobiliário.

5 Referências Bibliográficas

- DUDUBIOLOGICO. **Regressão Logística em R**. 1 nov. 2019. <Disponível em: <https://rpubs.com/dudubiologico/545528>>. Acesso em: 20 nov. 2025.
- MORAES, José Rodrigo de. **Modelo de Regressão Logística Binária com R**. Niterói: Universidade Federal Fluminense, 17 nov. 2016. Disponível em: <<http://www.estadisticacomr.uff.br/?p=598>>. Acesso em: 20 nov. 2025.
- R CORE TEAM. **R: A language and environment for statistical computing**. R Foundation for Statistical Computing, Vienna, Austria, 2023. Disponível em: <<https://www.R-project.org/>>.
- RODRIGUES, Kévin Allan Sales. **LASSO Clássico e Bayesiano**. São Paulo: Instituto de Matemática e Estatística da Universidade de São Paulo, [2018?]. Disponível em: <https://www.ime.usp.br/~kevinx/LASSO_Texto.pdf>. Acesso em: 20 nov. 2025.
- THE PENNSYLVANIA STATE UNIVERSITY. 13.1 - **Weighted Least Squares**. In: STAT 501: Regression Methods. [S.l.: s.n.], [20-?]. Disponível em: <<https://online.stat.psu.edu/stat501/lesson/13/13.1>>. Acesso em: 20 nov. 2025.
- TRUCIOS, Carlos. **Mínimos Quadrados Ordinários**. 1 abr. 2021. Disponível em: <<https://ctruciosm.github.io/posts/2021-04-01-minimos-quadrados-ordinarios/>>. Acesso em: 20 nov. 2025.